

# Challenge de RAG multimodal: Buscador de arte semántico

Curso 2025 - 2026

Sandra Conde González

Pablo Folgueira Galán

Repositorio de GitHub: <https://github.com/pfolgueira/buscador-arte-semantico>

## 1. Contexto y análisis del *dataset*

En este primer capítulo se introduce brevemente el problema que debemos resolver y cuáles son los principales retos que debemos superar. Además, se define el alcance del proyecto desarrollado y se analiza el conjunto de datos que vamos a utilizar.

### 1.1. Presentación del problema

Históricamente, la mayoría de los sistemas de búsqueda artísticos se han centrado en realizar consultas a partir de los metadatos de las obras, tales como el autor, la técnica empleada o el año en el que se finalizó la pieza. Sin embargo, no es tan frecuente encontrar buscadores que permitan recuperar obras a partir de su contenido o de elementos que aparezcan representados en ellas.

Para solucionar esta limitación, este proyecto tiene como objetivo utilizar distintas técnicas y herramientas de inteligencia artificial para desarrollar un buscador semántico de arte capaz de recuperar información basándose en características o elementos descriptivos propios de una obra. De esta forma, los usuarios podrán realizar consultas en lenguaje natural (por ejemplo, “un interior doméstico tranquilo iluminado por una lámpara” o “una escena nocturna con contrastes intensos entre luz y sombra”) y el sistema devolverá las obras que representen visualmente una escena similar, permitiendo así la búsqueda de elementos artísticos por su contenido visual, atmósfera o temática.

### 1.2. Desafíos y retos de implementación

El desarrollo de una solución que facilite la búsqueda semántica de obras artísticas plantea los siguientes desafíos:

- **Capturar el significado y los matices semánticos de las obras:** Superar la limitación de las búsquedas por palabras clave exactas en metadatos para lograr que el sistema comprenda el significado profundo de las representaciones visuales y de texto.
- **Implementación de un *pipeline* multimodal:** Diseñar e implementar flujos de trabajo eficientes que permitan procesar el contenido de las imágenes. Esto implica extraer descripciones precisas mediante Modelos de Lenguaje Visual (VLM) y generar representaciones numéricas o embeddings tanto del texto como directamente

de la imagen.

- **Evaluación de la calidad del sistema:** Al tratar con conceptos semánticos, determinar si el sistema funciona correctamente o si está devolviendo lo que espera el usuario es una tarea compleja y subjetiva. Por ello, definir claramente qué significa que el sistema “funcione bien” y asegurarse de que está devolviendo resultados relevantes para los usuarios supone un reto a la hora de implementar un sistema de estas características.

### 1.3. Alcance del proyecto

Este proyecto se enmarca dentro de la asignatura de Inteligencia Artificial en Aplicaciones Culturales como un *challenge* propuesto por *Management Solutions*<sup>1</sup>. En este contexto, el alcance abarca el diseño, la implementación y la evaluación de una arquitectura RAG (*Retrieval Augmented Generation*) enfocada en la búsqueda semántica de obras de arte.

Para ello, se tomará como punto de partida un conjunto de datos de *Kaggle*, correspondiente al *Rijksmuseum*<sup>2</sup>, que contiene cerca de 25.000 obras de arte con sus metadatos correspondientes y se utilizará para desarrollar una solución que estará compuesta por dos fases fundamentales:

- **Ingesta de datos:** esta primera fase consiste en realizar el procesamiento de las imágenes y la generación de descripciones para su almacenamiento como *embeddings* en una base de datos vectorial.
- **Recuperación:** esta fase se centra en desarrollar un mecanismo de *retrieval* que procese las peticiones del usuario y devuelva aquellas obras de arte cuyo contenido y significado semántico mejor respondan a la búsqueda realizada.

### 1.4. Análisis del *dataset*

Antes de comenzar con la implementación de la arquitectura de nuestro sistema, hemos realizado un análisis del conjunto de datos que íbamos a utilizar para comprobar si era necesario realizar algún tipo de preprocesamiento o tomar alguna decisión que afectase a fases posteriores del desarrollo.

En primer lugar, el *dataset* del Rijksmuseum está compuesto por un fichero csv de metadatos y una serie de carpetas que contienen las imágenes de los distintos tipos de obras de arte. La información de todas las obras viene recogida en el fichero 'metadata.csv', que cuenta con un identificador único para cada obra, su título, artista, fecha de finalización y tipo. Además, podemos ver que en total hay 24564 obras de arte distintas organizadas según su tipo, que puede ser *painting*, *photograph*, *photomechanical print* o *drawing*. De entre todas ellas, solamente hay una fila con un valor nulo en la columna artista, por lo que no será necesario realizar ningún preprocesamiento mucho más detallado sobre el conjunto de datos.

Antes de comenzar con el desarrollo del sistema, consideramos importante analizar la distribución de los datos para evitar cualquier sesgo de representación o predominancia de un tipo de obra concreto por encima de otros. En la figura 1 se muestra esta distribución y, en primer lugar, vemos que los tipos más predominantes son *drawing* y *photomechanical print*, por lo que hay una diferencia clara entre las distintas clases. Por

---

<sup>1</sup><https://www.managementsolutions.com/es>

<sup>2</sup><https://www.kaggle.com/datasets/lgmoneda/rijksmuseum>




Figura 1: Distribución de los tipos de obra en el conjunto de datos.

ello, con el objetivo de buscar un equilibrio entre que el sistema tenga un buen rendimiento y que haya una representación equitativa de todos los tipos de obras, vamos a tomar un subconjunto de 4000 imágenes, donde tengamos 1000 obras seleccionadas aleatoriamente de cada uno de los tipos. De esta forma, podremos construir un sistema lo suficientemente representativo y, escalable en un futuro, a la vez que evitamos que solamente se recuperen obras de un tipo determinado y eso afecte tanto al funcionamiento del sistema como a la satisfacción de los usuarios.

Para finalizar el análisis exploratorio del corpus de imágenes, decidimos comprobar si alguno de los archivos estaba corrupto y no se podía abrir para no tenerlo en cuenta a la hora de hacer la selección del subconjunto de imágenes, además de analizar la dimensión de las distintas imágenes por si fuera necesario algún tipo de preprocesamiento adicional.

Respecto a los archivos, vimos que de las casi 25000 obras solamente una no pudo abrirse correctamente, por lo que la eliminamos del *dataset* para evitar cualquier error durante las fases de ingesta o recuperación. En cuanto a la dimensión y resolución de las obras, los gráficos generados (figura 2) nos hacen pensar que los creadores ya han hecho algún tipo de preprocesamiento o estandarización de las imágenes para que su uso sea mucho más directo:

- **Distribución de la relación de aspecto (Histograma):** El conjunto de datos contiene imágenes con distintos formatos, entre los que encontramos un pico mayoritario justo por debajo de la relación de aspecto 1:1 (cuadrado), lo que indica una clara presencia de obras en formato vertical. Un segundo pico, algo más suave, se sitúa entre el 1.2 y el 1.5, agrupando las obras en formato horizontal o apaisado. Por lo general, no encontramos valores muy extremos, lo que confirma que no tendremos que trabajar con imágenes excesivamente panorámicas que pudieran ser malinterpretadas por el VLM, facilitando notablemente el trabajo.
- **Ancho vs Alto de las imágenes:** En el gráfico de dispersión podemos ver claramente que la mayoría de imágenes tiene un ancho de 1000 píxeles, lo que probable-




Figura 2: Dimensión y relación de aspecto de las imágenes del conjunto de datos.

mente signifique que este corpus ya ha pasado por un proceso de estandarización y redimensionado previo. En general, la mayoría de las resoluciones se encuentran en un rango de 250 a 2500 píxeles de alto, lo que supone una ventaja para el proyecto, ya que las imágenes tienen la calidad y resolución suficientes para que el VLM extraiga los matices artísticos y semánticos necesarios, permitiendo una correcta recuperación de obras de arte en base a su significado semántico.

## 2. Arquitectura propuesta

En esta sección se describe la arquitectura propuesta para construir un sistema RAG multimodal que permita a los usuarios buscar obras de arte por su contenido semántico. Esta solución se compone de una primera fase donde se realiza la ingesta, el procesamiento y el almacenamiento de los datos y, una segunda etapa en la que, a partir de una consulta del usuario, se recuperan aquellos casos más similares y relevantes.

La opción que hemos elegido para implementar nuestro sistema es la propuesta en el **Pipeline 2** (Imagen  $\rightarrow$  VLM  $\rightarrow$  Texto  $\rightarrow$  Embeddings) por dos razones principales. En primer lugar, pensamos que esta opción nos permite capturar en mayor profundidad el significado de las obras, sus matices y su contenido. De esta forma, podemos dar más libertad a los usuarios a la hora de hacer consultas, permitiéndoles preguntar por elementos y conceptos más abstractos de una obra que un modelo de *embeddings* no sería capaz de capturar, a diferencia de un VLM que tiene una mejor capacidad en este aspecto. La segunda razón que nos ha llevado a implementar este *pipeline* es nuestro interés en desarrollar una solución utilizando VLMs, una tecnología con la que no habíamos trabajado previamente.

A continuación, se detalla cada fase del proceso y la justificación de cada una de las decisiones tomadas durante el desarrollo:

### 2.1. Fase 1: Ingesta, procesamiento y almacenamiento de los datos

El objetivo de esta fase es preparar y almacenar los datos para, posteriormente, permitir a los usuarios realizar consultas semánticas sobre obras de arte. Como se muestra

en la figura 3, esta fase se compone de 4 pasos que se ejecutan en orden y se describen más en detalle a continuación:




Figura 3: Diagrama del pipeline propuesto para la ingesta y el almacenamiento de los datos.

### 2.1.1. Selección y preparación del dataset

En este primer paso partíamos del corpus de imágenes del Rijksmuseum, del que tomamos 1000 imágenes de cada una de las categorías (grabados, cuadros, fotografías e impresiones fotomecánicas) de forma aleatoria, como se explica en la sección 1.4.

El motivo de elegir estas 4000 imágenes fue mantener una distribución equitativa entre los distintos tipos de obra. De esta forma, evitamos sesgos de representación en el espacio vectorial y garantizamos que el sistema pueda recuperar cualquier tipo de pieza de manera justa, sin que una categoría predomine sobre las demás y afecte a la recuperación y visibilidad de los resultados. Además, este volumen de datos hace que nuestro RAG sea lo suficientemente representativo, permite que funcione con rapidez en la fase de recuperación y que el coste de procesamiento con el VLM no sea demasiado elevado.

### 2.1.2. Generación de Descripciones a través del VLM (Gemini 2.5 Flash Lite)

Una vez seleccionado el conjunto de 4000 obras de arte en el paso anterior, las imágenes se envían a un Modelo de Visión-Lenguaje (VLM) a través de la API correspondiente para generar descripciones textuales detalladas sobre su contenido visual. Para ello, hemos utilizado el modelo Gemini 2.5 Flash-Lite<sup>3</sup>, más ligero que otros de su misma familia y que está optimizado para ser eficiente y tener una baja latencia de respuesta, lo que nos ha permitido procesar las 4000 imágenes de forma sencilla y rápida. A pesar de ser un modelo ligero, mantiene una capacidad multimodal muy alta, logrando captar detalles sutiles de las obras de arte que pueden enriquecer las descripciones y mejorar el funcionamiento de nuestro RAG. Además, la facturación por tokens de este modelo es notablemente más barata que la de otros modelos de su misma categoría, pudiendo obtener descripciones ricas y detalladas para todo el dataset sin que el coste fuese excesivo y sin sacrificar la calidad de los textos generados.

Con el propósito de asegurar que el modelo sea capaz de extraer características tanto semánticas como técnicas que puedan ser útiles en la fase de recuperación, hemos utilizado un prompt (figura 4) estructurado en el que el modelo adopta el rol de un experto

<sup>3</sup><https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/2-5-flash-lite?hl=es2.5-flash-lite>

en historia del arte, identifica la categoría a la que pertenece la obra y describe su contenido, además de definir aspectos como el color o la atmósfera. Por último, también se le pide que devuelva una lista de palabras clave que puedan ayudar en la búsqueda de la obra.

Cabe destacar que el prompt está en inglés, ya que hemos considerado que el modelo podría funcionar algo mejor en este idioma y dar lugar a descripciones más detalladas y de mayor calidad. Como se puede observar en la figura 5, el modelo devuelve una descripción muy detallada de la obra correspondiente que sirve de base para la recuperación semántica. El hecho de que la información se almacene en inglés no supone una limitación para los usuarios, ya que como se explica en la siguiente sección, hemos utilizado un modelo de *embeddings* multilingüe para mapear las descripciones en un espacio vectorial, de forma que los usuarios podrán hacer consultas en diferentes idiomas.

**Prompt:**

*“Act as an art history expert. Your task is to analyze this image for an artwork information retrieval system. Begin the first sentence by explicitly identifying whether the work is a painting, a photograph, a photomechanical print, or a picture. Next, fluidly describe the main subject, the spatial composition, and the use of light. Integrate into the narrative details about the color palette, the technique (such as the type of brushstroke or photographic grain), and especially the atmosphere or mood it conveys (e.g., whether it is somber, vibrant, gloomy, or serene). Use specialized art vocabulary and make sure to mention key objects or symbols. At the end, add a comma-separated list of keywords including specific objects, symbols, or iconographical details that a user might use to search for this work.”*

Figura 4: Prompt diseñado para el análisis artístico.

### 2.1.3. Generación de Embeddings (BGE-m3)

Con las obras de arte ya descritas, el siguiente paso es transformar su contenido textual en *embeddings* para posteriormente, realizar búsquedas por similitud en base a la consulta de los usuarios. Para construir estas representaciones vectoriales hemos utilizado el modelo BGE-M3<sup>4</sup> por varios motivos. En primer lugar, al no ser modelos tan pesados como los modelos de lenguaje, hemos decidido utilizar uno que pudiésemos ejecutar en local y, de esta forma, ahorrarnos el coste de otros modelos que se ejecutan en la nube. Por otro lado, buscábamos un modelo que fuese multilingüe, de forma que los usuarios del sistema no estén restringidos a hacer las consultas únicamente en inglés y, por último, también era necesario que el modelo de *embeddings* fuese capaz de representar en el espacio vectorial textos relativamente largos y no solamente frases u oraciones cortas.

Teniendo estos aspectos en cuenta, decidimos quedarnos con BGE-M3, ya que es un modelo que podemos ejecutar en local y es capaz de soportar más de 100 idiomas diferentes, permitiendo que los usuarios realicen consultas semánticas en distintos idiomas manteniendo un buen rendimiento y una alta precisión en la recuperación de las obras de arte. Además, es capaz de procesar entradas de hasta 8192 tokens, evitando así cualquier problema con la longitud de las secuencias de entrada.

### 2.1.4. Almacenamiento Vectorial y Metadatos (ChromaDB)

El último paso de esta primera fase consiste en almacenar todos los datos procedentes de etapas anteriores para utilizarlos posteriormente en la fase de recuperación. Para ello,

---

<sup>4</sup><https://huggingface.co/BAAI/bge-m3>



**Salida:**

*“This painting depicts a solitary figure, likely Saint Jerome, in a moment of intense contemplation or penitence. The main subject, an elderly man with a flowing white beard and a halo of light emanating from behind his head, is shown kneeling on the ground, his gaze directed upwards in supplication or divine inspiration. He is clad in a vibrant crimson drapery that contrasts sharply with his pale, emaciated torso, emphasizing his ascetic lifestyle. The spatial composition is intimate and focused, with the figure dominating the foreground and middle ground. The background is rendered in deep, tenebrous shadows, characteristic of Caravaggesque chiaroscuro, which serves to heighten the drama and spiritual intensity of the scene. The use of light is masterful, with a strong raking light illuminating the figure from the upper left, casting deep shadows and sculpting his form with dramatic effect. The color palette is restrained, dominated by earthy browns and blacks in the background, punctuated by the vivid red of the drapery and the luminous white of the open book before him. The technique appears to be oil on canvas, with visible brushstrokes that lend a tactile quality to the rendering of flesh and fabric. The atmosphere conveyed is one of profound spiritual fervor, solitude, and introspection, bordering on anguish. Key objects include the open book, symbolizing scripture and learning, and a discarded red hat, possibly alluding to his past life as a cardinal or a symbol of worldly vanity renounced. The presence of a lion, partially obscured in the shadows to the left, is a traditional attribute of Saint Jerome, representing his taming of the wild beast. Saint Jerome, kneeling, penitent, red drapery, halo, open book, discarded red hat, lion, chiaroscuro, tenebrism, spiritual contemplation, asceticism, Caravaggesque”*

Figura 5: Salida generada por Gemini 2.5 Flash-Lite.

hemos utilizado ChromaDB<sup>5</sup>, una base de datos vectorial bastante ligera y optimizada para el manejo de *embeddings*.

El motivo principal por el que hemos decidido utilizarla es que permite almacenar simultáneamente el *embedding*, la descripción y los metadatos correspondientes a cada obra de arte. De esta forma, no es necesario trabajar con el fichero csv de metadatos original cada vez que el usuario haga una consulta, lo que agiliza todo el proceso.

Además, tener esta información integrada en la misma base de datos no solo facilita la búsqueda semántica de los vecinos más cercanos (K-NN), sino también la implementación de un filtrado híbrido si quisiésemos ampliar los objetivos del proyecto.

## 2.2. Fase 2: Búsqueda y Recuperación (*Retrieval*)

Esta segunda fase se centra en la recuperación de obras de arte, detallando los pasos desde que el usuario realiza una consulta hasta la visualización en la interfaz de los resultados recuperados de la base de datos vectorial.

<sup>5</sup><https://www.trychroma.com/products/chromadb>

# Buscador Semántico de Arte

Describe la atmósfera, los colores o los elementos de la obra que buscas.

A peaceful domestic interior bathed in warm morning sunli

6

Buscar

Figura 6: Interfaz de entrada del buscador de arte semántico. Se muestran el campo de texto para la consulta semántica, el selector para el número de resultados ( $k$ ) y el botón de acción.

## 2.2.1. Interfaz de Usuario y Parámetros de Consulta (*Frontend* en React)

Hemos desarrollado una interfaz web utilizando React y Tailwind CSS para que los usuarios puedan interactuar con el sistema de forma cómoda y sencilla. Hemos decidido utilizar estas tecnologías debido a que ya teníamos cierta experiencia y consideramos que se ajustan correctamente a las necesidades del proyecto, al permitirnos construir una *Single Page Application (SPA)* con la que los usuarios puedan interactuar y tener una experiencia fluida.

Como se muestra en la figura 6, la interfaz de nuestro buscador semántico de arte presenta un diseño sencillo y directo para los usuarios formada por 3 componentes principales:

- Campo de texto: área donde el usuario puede describir en lenguaje natural el contenido de las obras que pretende buscar (por ejemplo: “A peaceful domestic interior bathed in warm morning sunlight”).
- Selector numérico (parámetro  $k$ ): campo numérico, situado a la derecha del *input* de texto, que permite al usuario definir cuántos resultados desea recuperar y visualizar.
- Botón de búsqueda: botón con la etiqueta “Buscar” que, al ser pulsado, activa el flujo de recuperación en el *backend*, enviando la consulta y el parámetro  $k$  para recuperar las obras más similares.

Esta estructura clara permite al usuario interactuar con el sistema proporcionando los datos necesarios para realizar una recuperación semántica lo más precisa posible.

## 2.2.2. Vectorización de la consulta

Cuando el usuario pulsa el botón “Buscar”, se envía una petición al *backend* del sistema, que recibe la consulta textual introducida por el usuario junto con el parámetro de resultados a recuperar. Antes de realizar la búsqueda en el espacio vectorial de las obras más similares, es necesario generar un *embedding* para la consulta del usuario a partir de la cual calcular la similitud.

En este paso es importante tener en cuenta que debemos utilizar el mismo modelo de *embeddings* que utilizamos en la fase de ingesta (BGE-M3) para que tanto la consulta como las descripciones se mapeen en el mismo espacio vectorial y el sistema pueda recuperar los resultados adecuados. Además, gracias a la naturaleza multilingüe del



modelo de *embeddings* que hemos utilizado, el usuario puede introducir la consulta en diferentes idiomas y el sistema seguirá funcionando correctamente.

### 2.2.3. Búsqueda en el espacio vectorial de las obras más similares

Una vez se dispone del *embedding* de la consulta del usuario, se hace una búsqueda en nuestra base de datos (ChromaDB) para recuperar los  $k$  (parámetro introducido por el usuario) vecinos más similares a la consulta del usuario. Para el cálculo de similitud en ChromaDB se utiliza la métrica de producto interno (*inner product* o *ip*) en lugar de la similitud del coseno (*cosine similarity*). Dado que los embeddings generados previamente han sido normalizados, el cálculo del producto interno es matemáticamente equivalente a la similitud del coseno, pero computacionalmente mucho más eficiente y rápido, lo que reduce notablemente el tiempo de respuesta.

### 2.2.4. Presentación de los resultados al usuario

Con la búsqueda de los elementos más similares finalizada, nuestro *backend* envía al *frontend* las imágenes junto con su descripción detallada (generada por Gemini 2.5 Flash-Lite en la fase 1) y todos sus metadatos asociados (autor, año, tipo de obra, etc.) para poder mostrárselas al usuario.

En la figura 7 se muestra un ejemplo de la interfaz tras haber realizado la búsqueda para una consulta. Como puede verse, en la parte superior, se mantienen los campos que el usuario puede rellenar y modificar. Bajo esta sección, los resultados se despliegan en una cuadrícula con tarjetas correspondientes a cada una de las obras de arte recuperadas ordenadas por similitud. Cada una de estas tarjetas permite al usuario identificar de un vistazo la siguiente información:

- Obra de arte recuperada.
- El título de la obra y el nombre del artista.
- Métrica de similitud entre la consulta del usuario y la descripción de la obra de arte.

Este diseño permite que el usuario no solo acceda a las imágenes, sino que valide la coherencia semántica de los resultados devueltos por el RAG. No obstante, si quiere profundizar más en los detalles de una obra concreta, puede interactuar con las tarjetas para que se le muestre una ventana como la de la figura 8. En ella, el usuario puede ver la obra de arte al completo junto a toda su información disponible, además de la descripción generada en pasos anteriores y, a partir de la cual se ha calculado la similitud.

Hemos decidido mostrar la descripción completa generada por el VLM junto con los metadatos para añadir algo de interpretabilidad a nuestro sistema RAG, de forma que el usuario no solo reciba las imágenes más relevantes, sino que pueda leer el análisis de la obra y comprender por qué la búsqueda semántica ha determinado que esa imagen concreta responde a su intención de búsqueda.

## 3. Evaluación

En este capítulo se define el significado de que un sistema de este tipo funcione correctamente y se presenta una evaluación de la solución propuesta en el capítulo 2.

# Buscador Semántico de Arte

Describe la atmósfera, los colores o los elementos de la obra que buscas.

A peaceful domestic interior bathed in warm morning sunli

6

Buscar



**Taking a Nap**  
Alexander Hugo Bakker Korff  
Score: 0.664



**Interieur van De Wildbaan, het woo...**  
Henry Pauw van Wieldrecht  
Score: 0.656



**Neighborly Gossip**  
Bernardus Johannes Blommers  
Score: 0.650



**The Housewife**  
Abraham van Strij (I)  
Score: 0.645



**Peasant Family in their Cottage**  
Cornelis Kruseman  
Score: 0.645



**Man Eating from an Earthenware Pot**  
Daniel Boone  
Score: 0.644

Figura 7: Interfaz de usuario del buscador semántico. Se muestra una consulta sobre interiores domésticos con luz solar y la recuperación de los seis resultados con mayor puntuación de similitud (score)

10




Figura 8: La interfaz muestra la imagen junto a sus metadatos originales (título, autor, año y tipo) y la descripción generada por Gemini 2.5 Flash-Lite durante la fase de ingesta.

### 3.1. ¿Qué significa que el sistema “funcione bien”?

En un sistema RAG multimodal como el que hemos construido, no todos los usuarios esperan las mismas respuestas a partir de una consulta. Esto hace que evaluarlo sea una tarea compleja y subjetiva, para la que hemos definido una serie de criterios que nos permitan determinar si nuestro sistema funciona correctamente y resuelve el problema planteado en la sección 1.1. Los aspectos a tener en cuenta durante la evaluación son los siguientes:

- **Captura del contenido visual y los matices semánticos:** el primero es determinar si hemos sido capaces de superar la limitación de la búsqueda tradicional utilizando metadatos, de forma que, si un usuario pregunta por elementos o conceptos más abstractos (“atmósfera melancólica” o “paisaje nevado”), las imágenes recuperadas deben reflejar visualmente esos atributos. Esto demostraría que las descripciones generadas capturan correctamente el contenido y los matices de la obra y que el espacio vectorial mapea todos estos conceptos de la forma adecuada.

Además, otro punto que debemos considerar es que, debido a la arquitectura y modelos que hemos utilizado, nuestro sistema debe ser capaz de funcionar en otros idiomas distintos al inglés (idioma en el que se han generado las descripciones), permitiendo a los usuarios utilizar el sistema independientemente de la lengua que hablen sin perder calidad en las recuperaciones.

- **Rápido tiempo de respuesta:** para que nuestro sistema funcione correctamente, también es importante que el tiempo que transcurre desde que el usuario realiza una consulta hasta que obtiene los resultados sea lo más breve posible. En nuestro caso no es un problema muy notable, ya que estamos trabajando con un subconjunto de imágenes relativamente pequeño pero, de cara al despliegue de un sistema de este tipo en un entorno real, es un factor importante a considerar.
- **Interpretabilidad:** en este tipo de sistemas no solo es importante la recuperación, sino también ayudar al usuario a entender el por qué de los resultados que se le han devuelto. Por ello, debemos comprobar si los metadatos y la descripción que se muestran en las obras recuperadas son útiles para entender mejor el funcionamiento del sistema.
- **Equidad en la recuperación:** el último aspecto a tener en cuenta es que el sistema no debe favorecer ningún tipo de obra por encima de otro (por ejemplo, devolviendo solo cuadros en vez de fotografías o grabados), salvo que el usuario lo indique en su consulta. Parte de este problema tratamos de solucionarlo al seleccionar 1000 imágenes de cada categoría pero debemos asegurar que el sistema recupera distintas obras de forma equitativa.

### 3.2. Evaluación cuantitativa

Teniendo en cuenta los aspectos mencionados en el apartado anterior, seleccionamos un conjunto de prueba con el que medir de forma cuantitativa el funcionamiento de nuestro sistema. Este conjunto se compone de 13 obras de arte, seleccionadas manualmente del conjunto de imágenes utilizadas para la fase de ingesta para asegurar una representación equitativa de todos los tipos de obras y cubrir distintos contenidos, atmósferas o temáticas en ellas. Para cada una de estas obras se han definido dos consultas con dos enfoques diferentes:

- Consulta 1 (atmósfera y estética): enfocada en conceptos más abstractos, evaluando



Figura 9: Ejemplo de obra seleccionada para la evaluación cuantitativa.

cómo el sistema captura la paleta de colores, el uso de la luz (por ejemplo, contrastes intensos o luz matinal) y el estado de ánimo general que transmite la pieza.

- Consulta 2 (composición y elementos): centrada en el sujeto principal, la disposición espacial y los objetos, detalles iconográficos o símbolos específicos que el VLM debería haber identificado en su descripción.

Además, al haber utilizado el modelo multilingüe BGE-M3 para la generación de embeddings, las consultas se han realizado en inglés o español para evaluar el funcionamiento del sistema al trabajar con distintos idiomas.

Una vez seleccionado el conjunto de imágenes, utilizamos el modelo Gemini 3.1 Pro<sup>6</sup> para generar las consultas semánticas correspondientes a cada obra. En la figura 9 se muestra un ejemplo de obra utilizada para la evaluación, donde el LLM generó la consulta *“A peaceful pastoral landscape bathed in soft daylight, conveying a tranquil and idyllic rural mood with earthy colors and a clear blue sky.”* referente a su atmósfera y estética, y *“Una escena campestre con una mujer amamantando a un bebé junto a un pastor, rodeados de animales como un caballo blanco, vacas descansando y ovejas cerca de unas ruinas.”* acerca de su composición y elementos.

Tras haber probado el funcionamiento del sistema con todo el conjunto de prueba, obtuvimos los resultados que se muestran en la tabla 1. Podemos ver que el sistema alcanza un Recall@10 del 73 %, lo que significa que en la gran mayoría de las búsquedas la obra que queríamos encontrar aparecía entre los 10 primeros resultados. Además, la latencia es considerablemente baja (en torno a los 0.14 segundos de media), por lo que la respuesta es prácticamente instantánea y resulta en una experiencia de uso muy fluida. Cabe destacar que, aunque el volumen de datos con el que estamos trabajando no es muy grande (4000 imágenes), utilizar la métrica de producto interno para calcular la similitud con el conjunto completo del *dataset* debería ayudar a que la latencia no

<sup>6</sup><https://deepmind.google/models/gemini/pro/>

aumentase significativamente.

Otro punto destacable que hemos notado al analizar los casos de prueba es que el sistema tiende a cometer más errores en las consultas abstractas que en las que se centran en la composición y elementos de una obra. Esto tiene sentido, ya que recoger aspectos como la atmósfera o el sentimiento que transmite una obra es complejo y subjetivo, por lo que el VLM habrá tenido mucha más facilidad a la hora de identificar los elementos presentes en una obra que para recoger todos estos detalles más abstractos. Aun así, el hecho de que el *recall* suba casi un 15% al pasar de  $k = 5$  a  $k = 10$  demuestra que, aunque la obra concreta que buscamos no siempre aparezca en la primera posición, el sistema comprende la intención de la consulta y devuelve imágenes relacionadas en los puestos de mayor relevancia.

| Métrica         | Resultados     |                |
|-----------------|----------------|----------------|
|                 | $k = 5$        | $k = 10$       |
| Aciertos (Hits) | 15/26          | 19/26          |
| <b>Recall@k</b> | <b>57.69 %</b> | <b>73.08 %</b> |
| Latencia Media  | 0.145 s        | 0.132 s        |

Tabla 1: Resultados de la evaluación del sistema RAG multimodal.

### 3.3. Evaluación cualitativa

Para asegurar que el comportamiento general del sistema se ajustaba con mayor precisión a las necesidades de los usuarios, también hemos realizado una evaluación cualitativa a lo largo del desarrollo, comprobando que tanto las descripciones generadas por el VLM como sus *embeddings*, obtenidos con el modelo BGE-M3, eran coherentes con su obra correspondiente.

En esta evaluación, hemos probado nuestro sistema con distintas preguntas, que siguen el mismo enfoque que en la evaluación cuantitativa (sección 3.2, donde había preguntas más centradas en elementos concretos y otras sobre conceptos más amplios y abstractos. Algunos ejemplos de las preguntas que hemos utilizado son:

- A peaceful domestic interior bathed in warm morning sunlight.
- A somber and gloomy religious scene with dramatic shadows.
- A vibrant and energetic landscape with a sense of movement.
- Detailed oil painting with visible, thick brushstrokes and rich texture.
- A delicate photomechanical print with fine grain and high contrast.
- An intricate architectural sketch with precise perspective lines.
- Nobleman wearing a ruff collar holding a small mysterious object.
- A chaotic naval battle with ships, smoke, and rough waves.
- Still life with exotic fruits and silver tableware on a dark table.
- The passage of time and the decay of nature.
- A sense of profound loneliness and isolation in a city.
- Humanity’s struggle against the elements of the sea.

Por lo general, las sensaciones que nos han transmitido los resultados han sido bastante positivas, ya que las obras de arte obtenidas se corresponden en gran medida con la consulta introducida y no hemos detectado un sesgo hacia un tipo de obra determinado, ya que gracias al conjunto de imágenes que seleccionamos para trabajar, todos los tipos están representados en la misma medida y la recuperación se basa únicamente en su contenido. Además, al fijarnos en las descripciones generadas por el VLM para las obras recuperadas, se podían identificar elementos relacionados con la consulta original, lo que aumenta la interpretabilidad del sistema y ayuda a los usuarios a comprender mejor el por qué de los resultados devueltos por nuestro RAG multimodal.

## 4. Análisis final y conclusiones del proyecto

Tras haber desarrollado y evaluado nuestro buscador semántico de obras de arte, podemos concluir que hemos sido capaces de construir un sistema capaz de superar las limitaciones de la búsqueda por metadatos o palabras clave, permitiendo recuperar obras de arte a partir de su contenido visual, su atmósfera o su temática. A continuación se comentan las conclusiones más relevantes extraídas de las distintas fases del proyecto y de los desafíos que hemos tenido que superar:

- **Comprensión del contenido y significado de las obras:** gracias a las técnicas y herramientas de inteligencia artificial que hemos utilizado, nuestro RAG es capaz de superar algunas de las limitaciones de los sistemas tradicionales y manejar conceptos propios del contenido representado en las obras de arte. Además, dado que en la base de datos que hemos utilizado se almacenan las descripciones y los embeddings junto a los metadatos originales de las obras, sería interesante combinar la búsqueda por similitud semántica con filtros exactos (autor, tipo de obra, fecha, etc.) para dar más libertad y flexibilidad a los usuarios a la hora de hacer las consultas.

Además, la capacidad del sistema para manejar consultas en distintos idiomas es algo muy positivo, aunque sería interesante poder realizar una evaluación más extensa con usuarios, que además de aportar información sobre otros aspectos del sistema que se podrían mejorar, probasen su funcionamiento en otros idiomas que no fuesen solamente inglés y español, para asegurar que no existe ningún tipo de limitación en este sentido.

- **Eficacia del pipeline multimodal con VLM:** tras haber evaluado el sistema, consideramos que la elección del *pipeline 2* para tratar de dar a los usuarios más libertad a la hora de hacer consultas fue un acierto, ya que nos ha permitido capturar matices semánticos que no habríamos podido representar de la misma forma utilizando directamente un modelo de *embeddings*, donde los usuarios podrían verse más limitados a consultas relacionadas únicamente con el contenido de las obras, sin poder explorar otros aspectos como los sentimientos que transmite, la paleta de colores utilizada o la técnica empleada.
- **Escalabilidad y mejoras en la evaluación:** Aunque los resultados de evaluación han sido positivos tanto en tiempos de latencia como en la recuperación, es importante tener en cuenta que hemos trabajado con un subconjunto reducido de imágenes. Si en un futuro decidiésemos ampliar el proyecto, sería necesario considerar nuevos aspectos de implementación para solucionar problemas que pudiesen aparecer. Además, para obtener conclusiones más realistas, sería conveniente que parte del trabajo futuro lo dedicásemos a construir un *dataset* de prueba más ex-

tenso y validado por humanos con el que poder hacer más pruebas para evaluar el rendimiento real del sistema y adaptarlo a las necesidades que puedan tener los usuarios.